

Projet Deep Learning

Franck Chen

10 décembre 2024

Introduction

Plan

- ▶ Présentation de la méthode : f-GAN
- ▶ Mes résultats
- ▶ Limites

Présentation de la méthode : f-GAN

f-divergence

La **f-divergence** est une mesure de la différence entre deux distributions de probabilités. Pour une fonction génératrice f , elle est définie par la formule suivante :

$$D_f(P \parallel Q) = \int_{\mathcal{X}} q(x) f\left(\frac{p(x)}{q(x)}\right) dx$$

où :

- ▶ P et Q sont des distributions de probabilités avec des densités respectives $p(x)$ et $q(x)$,
- ▶ $f : \mathbb{R}^+ \rightarrow \mathbb{R}$ est une fonction convexe, semi-continue inférieure qui satisfait la condition $f(1) = 0$.

Présentation de la méthode : f-GAN

Le conjugué de f

Le conjugué de la fonction f , noté f^* , est défini comme suit :

$$f^*(t) = \sup_{u \in \text{dom}_f} \{ut - f(u)\}$$

f peut être exprimée en fonction de son conjugué f^* à travers la relation suivante :

$$f(u) = \sup_{t \in \text{dom}_{f^*}} \{ut - f^*(t)\}$$

Propriétés :

- ▶ $f^{**} = f$
- ▶ La fonction f^* est également convexe et semi-continue inférieure.

Présentation de la méthode : f-GAN

Expression de la f-divergence et minorisation

La f-divergence peut être exprimée de la manière suivante :

$$\begin{aligned} D_f(P \parallel Q) &= \int_{\mathcal{X}} q(x) \sup_{t \in \text{dom}_{f^*}} \left\{ \frac{p(x)}{q(x)} t - f^*(t) \right\} dx \\ &\geq \sup_{T \in \mathcal{T}} \left(\int_{\mathcal{X}} p(x) T(x) dx - \int_{\mathcal{X}} q(x) f^*(T(x)) dx \right) \\ &= \sup_{T \in \mathcal{T}} (\mathbb{E}_{x \sim P}[T(x)] - \mathbb{E}_{x \sim Q}[f^*(T(x))]) \end{aligned} \quad (1)$$

où \mathcal{T} est une classe arbitraire de fonctions $T : \mathcal{X} \rightarrow \mathbb{R}$.

Présentation de la méthode : f-GAN

La fonction optimale $T^*(x)$ pour la f-divergence

Dans le cadre de l'optimisation de la borne inférieure de la f-divergence, la **fonction optimale** $T^*(x)$ est obtenue en prenant la dérivée de la borne inférieure par rapport à T :

$$T^*(x) = f' \left(\frac{p(x)}{q(x)} \right),$$

où :

- ▶ $p(x)$ est la densité de la distribution réelle P ,
- ▶ $q(x)$ est la densité de la distribution générée Q .

Cette fonction $T^*(x)$ permet d'atteindre le supremum dans (1).
Mais en pratique, nous n'avons pas accès à $T^*(x)$.

Présentation de la méthode : f-GAN

La fonction objective F et son intérêt

La fonction objective F est utilisée pour l'optimisation des f-GAN.
Elle est définie comme suit :

$$F(\theta, \omega) = \mathbb{E}_{x \sim P}[T_{\omega}(x)] - \mathbb{E}_{x \sim Q_{\theta}}[f^*(T_{\omega}(x))]$$

Où :

- ▶ $T_{\omega}(x)$ est le score du discriminateur sur les images
- ▶ $\mathbb{E}_{x \sim P}[T_{\omega}(x)]$ est la moyenne des scores du discriminateur sur les **images réelles**.
- ▶ $\mathbb{E}_{x \sim Q_{\theta}}[f^*(T_{\omega}(x))]$ est la moyenne des scores du discriminateur sur les **images générées**.
- ▶ F mesure la divergence entre les distributions P et Q_{θ} .

Présentation de la méthode : f-GAN

Nouvelle forme de T et son intégration dans F

La fonction $T_\omega(x)$ peut être exprimée sous une nouvelle forme :

$$T_\omega(x) = g_f(V_\omega(x))$$

où :

- ▶ $V_\omega : \mathcal{X} \rightarrow \mathbb{R}$ représente le discriminateur,
- ▶ $g_f : \mathbb{R} \rightarrow \text{dom}_{f^*}$ est une fonction d'activation spécifique au choix de la f-divergence.

En utilisant cette nouvelle forme de $T_\omega(x)$, la fonction objective devient :

$$F(\theta, \omega) = \mathbb{E}_{x \sim P}[g_f(V_\omega(x))] - \mathbb{E}_{x \sim Q_\theta}[f^*(g_f(V_\omega(x)))]$$

Présentation de la méthode : f-GAN

Fonctions de perte du générateur et du discriminateur

$$F(\theta, \omega) = \mathbb{E}_{x \sim P}[g_f(V_\omega(x))] - \mathbb{E}_{x \sim Q_\theta}[f^*(g_f(V_\omega(x)))]$$

- Le **discriminateur** cherche à maximiser F , mesurant sa capacité à distinguer les vraies données des générées.
- Le **générateur** cherche à minimiser F , pour produire des données plus réalistes.

Fonctions de perte :

$$L_D = -(\mathbb{E}_{x \sim P}[g_f(V_\omega(x))] - \mathbb{E}_{x \sim Q_\theta}[f^*(g_f(V_\omega(x)))])$$

$$L_G = -\mathbb{E}_{x \sim Q_\theta}[f^*(g_f(V_\omega(x)))]$$

Présentation de la méthode : f-GAN

$$F(\theta, \omega) = \mathbb{E}_{x \sim P}[g_f(V_\omega(x))] - \mathbb{E}_{x \sim Q_\theta}[f^*(g_f(V_\omega(x)))]$$

Table: Différentes divergences et leurs fonctions associées.

Divergence $D_f(P \parallel Q)$	Fonction g_f	Domaine de f^*	Conjugué $f^*(t)$	$f'(1)$
Kullback-Leibler (KL)	ν	\mathbb{R}	$\exp(t - 1)$	1
Reverse KL	$-\exp(-\nu)$	\mathbb{R}^-	$-1 - \log(-t)$	-1
Pearson Chi-Square	ν	\mathbb{R}	$\frac{1}{4}t^2 + t$	0
Squared Hellinger	$1 - \exp(-\nu)$	$t < 1$	$\frac{t}{1-t}$	0
Jensen-Shannon	$\log(2) - \log(1 + \exp(-\nu))$	$t < \log(2)$	$-\log(2 - \exp(t))$	0
GAN	$-\log(1 + \exp(-\nu))$	\mathbb{R}^-	$-\log(1 - \exp(t))$	$-\log(2)$

Présentation de la méthode : f-GAN

$$F(\theta, \omega) = \mathbb{E}_{x \sim P}[g_f(V_\omega(x))] - \mathbb{E}_{x \sim Q_\theta}[f^*(g_f(V_\omega(x)))]$$

Table: Différentes divergences et leurs fonctions associées.

Divergence $D_f(P \parallel Q)$	Fonction de divergence
Kullback-Leibler (KL)	$\int_{\mathcal{X}} p(x) \log \left(\frac{p(x)}{q(x)} \right) dx$
Reverse KL	$\int_{\mathcal{X}} q(x) \log \left(\frac{q(x)}{p(x)} \right) dx$
Pearson Chi-Square	$\int_{\mathcal{X}} \frac{(p(x)-q(x))^2}{q(x)} dx$
Squared Hellinger	$\int_{\mathcal{X}} \left(\sqrt{p(x)} - \sqrt{q(x)} \right)^2 dx$
Jensen-Shannon	$\frac{1}{2} \int_{\mathcal{X}} p(x) \log \left(\frac{2p(x)}{p(x)+q(x)} \right) dx + q(x) \log \left(\frac{2q(x)}{p(x)+q(x)} \right) dx$
GAN	$\int_{\mathcal{X}} p(x) \log \left(\frac{2p(x)}{p(x)+q(x)} \right) dx + q(x) \log \left(\frac{2q(x)}{p(x)+q(x)} \right) dx - \log(4)$

Présentation de la méthode : f-GAN

Analyse de Kullback-Leibler

Raisonnement :

$$D_f(P \parallel Q) = \int_{\mathcal{X}} p(x) \log \left(\frac{p(x)}{q(x)} \right) dx$$

► **Lorsque $p(x)$ est grand :**

- La divergence $D_f(P \parallel Q)$ devient très élevée, ce qui incite le modèle génératif $q(x)$ à **augmenter considérablement** $q(x)$ dans ces zones pour réduire la divergence.

► **Lorsque $p(x)$ est faible :**

- La divergence $D_f(P \parallel Q)$ ne devient pas aussi élevée, ce qui incite le modèle génératif $q(x)$ à **diminuer légèrement** $q(x)$ dans ces zones pour réduire la divergence.

Présentation de la méthode : f-GAN

Analyse de Kullback-Leibler

Graphiquement :




Figure: Illustration des densités de probabilité réelle $P(x)$ et générée $Q(x)$

Présentation de la méthode : f-GAN

Analyse de Reverse Kullback-Leibler

Raisonnement :

$$D_f(P \parallel Q) = \int_{\mathcal{X}} q(x) \log \left(\frac{q(x)}{p(x)} \right) dx$$

► Lorsque $p(x)$ est grand :

- La divergence $D_f(P \parallel Q)$ ne devient pas très élevée, ce qui incite le modèle génératif $q(x)$ à **augmenter légèrement** $q(x)$ dans ces zones pour réduire la divergence.

► Lorsque $p(x)$ est faible :

- La divergence $D_f(P \parallel Q)$ devient élevée, ce qui incite le modèle génératif $q(x)$ à **diminuer considérablement** $q(x)$ dans ces zones pour réduire la divergence.

Présentation de la méthode : f-GAN

Analyse de Reverse Kullback-Leibler

Graphiquement :




Figure: Illustration des densités de probabilité réelle $P(x)$ et générée $Q(x)$

Mes Résultats

VANILLA P = 0,54 R = 0,21



Figure: GAN

Précision : 54% ~

Rappel : 21% ~



Figure: Jensen-Shannon

Précision : 57% ↑

Rappel : 25% ↑

Mes Résultats

VANILLA $P = 0,54$ $R = 0,21$



Figure: Kullback-Leibler

Précision : 51% ↓

Rappel : 26% ↑



Figure: Reverse Kullback-Leibler

Précision : 56% ↑

Rappel : 21% ↓

Mes Résultats

VANILLA P = 0,54 R = 0,21



Figure: Pearson Chi-Squared

Précision : 55% ~

Rappel : 30% ↑




Figure: Squared Hellinger

Précision : 57% ↑

Rappel : 24% ↑

Limites : instabilité




Figure: Représentation des différentes fonctions d'activation g_f .

Solutions :

- ▶ Clamper les scores du discriminateur sur les images générées **par le bas**
- ▶ Clamper les scores du discriminateur sur les images réelles **par le haut**
- ▶ Pre-train un GAN classique puis faire 20 epochs avec la nouvelle loss

Sources

- ▶ Sebastian Nowozin, Botond Cseke, Ryota Tomioka. *f*-GAN: Training Generative Neural Samplers using Variational Divergence Minimization.
<https://arxiv.org/abs/1606.00709>
- ▶ Dibya Ghosh. *KL Divergence for Machine Learning*.
<https://dibyaghosh.com/blog/probability/kldivergence.html>